

Gelişmiş Deniz Gözlemi: SAR Tabanlı Gemi Tespiti için CNN Algoritmalarının Kullanımı

Özet:

Bu çalışma, Sentinel-1 uydu verileri ile Faster R-CNN algoritmasını birleştirerek gemi tespiti konusunda %86,11 doğruluk oranı elde etmiştir. Faster R-CNN, derin öğrenmeye dayalı bir nesne algılama çerçevesi olup, SAR (Sentetik Açıklıklı Radar) görüntülerinde üstün performans göstermektedir. Elde edilen sonuçlar, deniz gözetimi ve gemi trafiği yönetimi gibi uygulamalarda önemli bir potansiyele sahip olup, deniz taşımacılığının emniyet ve güvenliğini artırmaya yönelik katkılar sunmaktadır.

Gemi Tespiti ve Derin Öğrenme Yaklaşımları:

Gemi tespiti, deniz güvenliği ve çevresel izleme gibi alanlarda kritik öneme sahiptir. Son yıllarda uydu ve radar görüntüleme ile derin öğrenme algoritmaları (özellikle CNN ve Faster R-CNN) bu alanda önemli ilerlemeler sağlamıştır. Faster R-CNN, bölge öneri ağı (RPN) kullanarak nesneleri yüksek doğrulukla tespit eder. Sentetik açıklıklı radar (SAR) görüntüleri de hava koşullarından bağımsız olarak gemi tespitinde yaygın olarak kullanılır. Çalışmalar, Faster R-CNN ve SAR verilerinin bir arada kullanıldığında %86,11 doğruluk gibi yüksek başarı oranlarına ulaştığını göstermektedir.

Materyal ve Yöntem

Çalışma Alanı

Mersin Limanı, Akdeniz'in doğu kıyısında yer alan ve Türkiye'nin en büyük limanlarından biridir. Liman, Roma dönemine kadar uzanan köklü bir geçmişe sahiptir ve günümüzde Türkiye'nin uluslararası ticaretinde önemli bir rol oynamaktadır. Modern konteyner terminalleri ve lojistik tesislerle donatılan Mersin Limanı, Avrupa, Orta Doğu ve Asya pazarlarına erişim sağlamaktadır. Liman ayrıca bölge ekonomisine katkıda bulunarak istihdam olanakları sunmaktadır.

Veri

Bu çalışmada kullanılan veriler, Avrupa Uzay Ajansı (ESA) tarafından geliştirilen Sentinel-1 uydusundan elde edilmiştir. Sentinel-1, C-bandında çalışan ve çift polarizasyon (VV ve VH) özelliklerine sahip Sentetik Açıklıklı Radar (SAR) verileri sağlamaktadır. VH polarizasyonu, karmaşık geometrilere sahip küçük gemilerin ve deniz yüzeyi özelliklerinin tespitinde etkili olup, aynı zamanda kara uygulamaları için de değerlidir. Bu özellikler, denizcilik ve oşinografik uygulamalar için zengin veri sağlamaktadır. Sentinel-1'in teknik özellikleri arasında 5.405 GHz frekans, 400 km'ye kadar tarama genişliği ve 6-12 günlük yeniden ziyaret süresi bulunmaktadır.

Yöntem

Çalışmada gemilerin tespiti ve izlenmesi amacıyla SARfish algoritması kullanılmıştır. SARfish, SAR görüntüleri ile Faster R-CNN algoritmasını birleştirerek gemi algılama sürecini gerçekleştirmektedir. Algoritma, SAR görüntülerindeki gürültü ve benekleri temizledikten sonra, derin sinir ağı ile özellik çıkarımı yapmaktadır. Daha sonra Faster R-CNN algoritması ile gemilerin yerini ve türünü yüksek doğrulukla belirlemektedir. SARfish, %92,9 ortalama hassasiyetle gemi tespiti sağlamış ve bu doğruluk oranı, denizcilik uygulamaları için önemli bir başarı olarak değerlendirilmektedir.

Faster R-CNN algoritması, konvolüsyonel özellik haritaları üzerinden nesne tespiti gerçekleştiren gelişmiş bir derin öğrenme tabanlı yöntemdir. Algoritmanın temel bileşenleri, Bölge Öneri Ağı (RPN) ve sınıflandırıcı ağıdır. RPN, nesne olasılıklarını hesaplayarak öneri bölgeleri oluştururken, sınıflandırıcı ağ ise bu bölgelerdeki nesneleri tanımlar ve sınırlayıcı kutuların konumunu hassas bir

şekilde ayarlar. Böylece, SARfish algoritması SAR görüntülerinde gemi hareketlerini ve davranışlarını başarılı bir şekilde analiz edebilmektedir.

Sonuç olarak, SARfish algoritması, denizcilik uygulamalarında gemi trafiği yönetimi, çevresel izleme ve deniz güvenliği gibi alanlarda etkili bir çözüm sunmaktadır. Açık kaynak yapısı sayesinde araştırmacılar ve uygulayıcılar için esnek ve özelleştirilebilir bir platform sağlamaktadır.

Bulgular

Önerilen gemi tespit algoritması, Faster R-CNN mimarisi ile Sentinel-1 VH SAR görüntüleri üzerinde uygulanmış ve çeşitli gemi türlerini yüksek doğrulukla tespit etmiştir. Algoritma, konvolüsyonel sinir ağları ve bölge öneri ağlarını birleştirerek gemilerin konumlarını belirlemiş ve dağılımlarını harita üzerinde göstermiştir. Elde edilen sonuçlara göre, algoritma küçük balıkçı teknelerinden büyük kargo gemilerine kadar geniş bir yelpazede başarılı olmuştur.

Test veri kümesi üzerinde algoritmanın doğruluğu %86,11 olarak hesaplanmış, kesinlik (precision) %84,54 ve geri çağırma (recall) %89,03 değerlerine ulaşmıştır. Yanlış pozitif oranının düşük olması, algoritmanın görüntülerdeki diğer özellikleri gemi olarak yanlış tanımlamadığını göstermektedir. Bu bulgular, algoritmanın gerçek zamanlı gemi algılama ve gözetleme sistemlerinde kullanılabilecek potansiyele sahip olduğunu ortaya koymaktadır.

SONUÇLAR

Bu çalışmada, Sentinel-1 VH SAR görüntülerini kullanarak Faster R-CNN tabanlı bir gemi algılama algoritmasının potansiyeli incelenmiştir. Algoritma, yüksek doğruluk ve düşük yanlış pozitif oranıyla çeşitli boyut ve tipteki gemileri başarıyla tespit etmiştir. Bu sonuçlar, derin öğrenme ve SAR görüntülerinin gemi tespitinde etkili olduğunu göstermektedir. Çalışma, deniz güvenliği ve gözetimi için doğru ve güvenilir tespit algoritmalarının önemini vurgularken, gelecekteki araştırmalar için de umut verici bir yaklaşım sunmaktadır.

Mask R-CNN İle Uydu Görüntülerinde Gemi Tespiti

Özet:

Son yıllarda derin öğrenme alanındaki gelişmeler, uzaktan algılama görüntülerinde gemi tespiti konusunda önemli ilerlemeler sağlamıştır. Özellikle konvolüsyonel sinir ağları (CNN), gemi tespiti için başarıyla kullanılmaktadır. Uydu görüntülerinin kalitesinin artması, gemilerin ve küçük nesnelerin tespitini kolaylaştırmıştır. Bu çalışmada, optik uydu görüntülerindeki gemileri tespit etmek için Mask R-CNN modeli kullanılmıştır. Modelin performansını değerlendirmek amacıyla, gemilerin yoğun olduğu alanlardan 1 metre çözünürlüklü 1838 uydu görüntüsü toplanmış ve gemiler GIS yazılımı ile etiketlenerek veri setleri oluşturulmuştur. Sonuçlar, modelin zorlu koşullarda bile gemileri başarıyla tespit edebildiğini, ancak birbirine yakın gemilerin tespitinde hatalar yapabildiğini göstermiştir.

Uzaktan algılama görüntülerinde gemi tespiti, ülke karasularının gözetimi, güvenliği, yönetimi ve deniz taşımacılığı gibi stratejik alanlarda önemli bir uygulama alanı bulmaktadır. Bu bağlamda, son yıllarda yüksek çözünürlüklü uydu görüntülerinin artan erişilebilirliği ve derin öğrenme tabanlı yöntemlerin gelişimi, gemilerin otomatik olarak tespit edilmesine yönelik çalışmaları hızlandırmıştır. Geleneksel makine öğrenimi yöntemlerinin sınırlılıkları, özellikle girdi verilerinin eğitim standardından sapması durumunda performans düşüşleri yaşanması, derin öğrenme modellerinin bu alanda öne çıkmasına neden olmuştur.

Konvolüsyonel Sinir Ağları (CNN), görüntü sınıflandırma ve nesne tespiti gibi görevlerde etkili sonuçlar vermektedir. Ancak, nesne tespiti gibi karmaşık görevler için CNN tabanlı modellerin uyarlanması gerekmektedir. Bu doğrultuda, bölge-tabanlı konvolüsyonel sinir ağları (R-CNN) ve türevleri, nesne aday bölge önerilmesi ve sınıflandırılması süreçlerini birleştirerek daha etkili çözümler sunmaktadır. Bu çalışmada, Mask R-CNN modeli kullanılarak uydu görüntülerindeki gemilerin tespiti gerçekleştirilmiştir. Mask R-CNN, nesnelerin sınırlayıcı kutularının yanı sıra piksel düzeyinde maskelerle işaretlenmesini sağlayarak daha detaylı bir tespit imkânı sunmaktadır.

Çalışma kapsamında, gemilerin yoğun olarak bulunduğu bölgelerden elde edilen yüksek çözünürlüklü uydu görüntüleri kullanılarak bir veri seti oluşturulmuştur. Bu veri seti üzerinde Mask R-CNN modeli eğitilmiş ve modelin performansı çeşitli metriklerle değerlendirilmiştir. Elde edilen bulgular, modelin genel olarak başarılı sonuçlar verdiğini, ancak özellikle birbirine yakın konumlanmış gemilerin tespitinde sınırlılıklar yaşadığını ortaya koymaktadır. Bu çalışma, uydu görüntülerinde gemi tespiti için derin öğrenme tabanlı yöntemlerin potansiyelini ve mevcut kısıtlamalarını inceleyerek literatüre katkı sağlamayı amaçlamaktadır.

Materyal ve Yöntem

Bu çalışmada, uydu görüntülerindeki gemilerin tespiti için **Mask R-CNN** modeli kullanılmıştır. Çalışmanın genel akışı, ham görüntülerin işlenmesi, etiketlenmesi, veri setlerinin oluşturulması, modelin eğitilmesi ve test görüntüleri üzerinde tespit performansının değerlendirilmesi şeklindedir. Bu bölümde, kullanılan veri setleri, yöntem, model eğitimi ve değerlendirme metrikleri detaylı olarak açıklanmaktadır.

Veri Setleri

Çalışmada, **Google Earth** tarafından sağlanan **1 metre mekânsal çözünürlüklü RGB uydu görüntüleri** kullanılmıştır. Görüntüler, açık denizler, kıyı bölgeleri ve iç sular gibi farklı coğrafyalardan toplanmıştır. Toplamda **1838 adet 768x768 piksel boyutunda görüntü** işlenmiş ve bu görüntülerdeki **3279 gemi**, bir **GIS yazılımı** kullanılarak manuel olarak sayısallaştırılmıştır. Veri seti, eğitim, validasyon ve test olmak üzere üç alt kümeye ayrılmıştır:

Yöntem

Çalışmada, **Mask R-CNN** modeli kullanılarak uydu görüntülerindeki gemilerin tespiti gerçekleştirilmiştir. Mask R-CNN, dört temel modülden oluşan bölge-tabanlı bir derin öğrenme modelidir:

1. **Özellik Çıkarım Ağı:** Girdi görüntüsünden konvolüsyonel özellik haritaları çıkarılır. Bu çalışmada, **Özellik Piramit Ağı (FPN)** kullanılarak farklı ölçeklerde özellik haritaları üretilmiştir.
2. **Bölge Öneri Ağı (RPN):** Görüntüde nesne olma potansiyeli taşıyan bölgeler önerilir.
3. **RoI Hizalama:** Önerilen bölgeler, sabit boyutlu özellik haritalarına dönüştürülür.
4. **R-CNN Modülü:** Önerilen bölgeler sınıflandırılır, sınırlayıcı kutular ve maskeler oluşturulur.

Mask R-CNN, nesnelerin sınırlayıcı kutularının yanı sıra piksel düzeyinde maskelerle işaretlenmesini sağlayarak daha detaylı bir tespit imkânı sunmaktadır. Model, farklı ölçeklerdeki nesneleri tespit edebilmek için FPN'den yararlanır ve önerilen nesnelerin büyüklüğüne göre uygun özellik haritalarını seçer.

Model Eğitimi

Model eğitimi için **Tensorflow** ve **Keras** derin öğrenme çerçeveleri kullanılmıştır. Omurga ağ olarak, **COCO veri seti** üzerinde ön-eğitim almış **ResNet-101** mimarisi tercih edilmiştir. Model, **80.000 iterasyon** boyunca eğitilmiş ve eğitim sürecinde **0,001 öğrenme oranı**, **0,0001 ağırlık bozunumu** ve **0,9 momentum** değerleri kullanılmıştır. Eğitim, **Nvidia GeForce GTX 1080 Ti** ekran kartına sahip bir bilgisayarda gerçekleştirilmiştir.

Tespit Değerlendirme Metrikleri

Modelin performansı, **kesinlik (precision)**, **geri getirme (recall)** ve **F1 skoru** gibi metrikler kullanılarak değerlendirilmiştir. Bu metrikler, doğru tespitler (TP), yanlış tespitler (FP) ve gözden kaçan nesneler (FN) üzerinden hesaplanmaktadır:

Tespitlerin doğruluğu, **Intersection over Union (IoU)** değeri üzerinden değerlendirilmiş ve $IoU > 0,5$ olan tespitler doğru kabul edilmiştir.

Bulgular ve Tartışma

Bu çalışmada, Mask R-CNN modeli için en uygun güven eşiğinin belirlenmesine yönelik deneyler gerçekleştirilmiştir. Deneyler sonucunda, 0,5 değerinin en iyi tespit performansını sağladığı bulunmuştur. Bu eşik değeriyle model, test kümesinde 604 yer doğruluğunun 558'ini başarılı şekilde tespit ederken, 46 örneği gözden kaçırmış ve 58 yanlış alarm üretmiştir. Buna göre modelin geri getirme oranı 0,9238, kesinliği 0,9058 ve F1-skoru 0,9148 olarak hesaplanmıştır.

Modelin uydu görüntüleri üzerindeki performansı değerlendirildiğinde, farklı senaryolarda çeşitli hata türleri gözlemlenmiştir. Singapur Limanı'na ait görüntüde model, toplam sekiz gemiden yedisini doğru tespit etmiş, ancak büyük bir gemiye yanaşmış olan küçük bir gemiyi gözden kaçırmıştır. Hong Kong'daki askeri limanı içeren uydu görüntüsünde ise model, on gemiden sekizini tespit ederken, iki gemiyi gözden kaçırmış ve bir kara parçasını hatalı şekilde gemi olarak sınıflandırmıştır. Benzer şekilde, Rotterdam'daki bir iç limana ait uydu görüntüsünde model, dokuz gemiden yedisini doğru tespit etmiş, ikisini ise gözden kaçırmıştır.

Modelin, birbirine yakın konumlanmış gemileri tek nesne olarak algılama eğiliminde olduğu gözlemlenmiştir. Bu durum, Faster R-CNN gibi bölge tabanlı nesne tespit algoritmalarında da karşılaşılan bir sorundur. Literatürde, bu problemin RPN (Region Proposal Network) aşamasında kullanılan dikdörtgen sınırlayıcı kutular nedeniyle ortaya çıktığı belirtilmektedir. Çözüm önerisi olarak, döndürülmüş sınırlayıcı kutuların kullanılması gerektiği ifade edilmektedir. Bu yaklaşımın,

özellikle yakın konumlanmış nesnelerin daha doğru şekilde ayrıştırılmasına katkı sağlayabileceği düşünülmektedir.

Sonuç

Bu çalışmada, Mask R-CNN modeli kullanılarak uydu görüntülerindeki gemiler tespit edilmiş ve performansı değerlendirilmiştir. Model, 0,5 güven eşiği ile test verisindeki 604 geminin 558'ini doğru tespit etmiş, 58 yanlış alarm üretmiştir. Özellikle birbirine yakın gemilerin tek bir nesne olarak algılanması veya bazı gemilerin gözden kaçırılması en sık karşılaşılan hata türleri olmuştur. Ayrıca, bazı kara parçalarının gemi olarak sınıflandırıldığı ve karaya yanaşmış gemilerin bazen tespit edilemediği gözlemlenmiştir. Gelecek çalışmalarda, bu hataların nedenlerini araştırmak ve Mask R-CNN'yi farklı modellerle karşılaştırmak amaçlanmaktadır.

GEMİ TESPİTİ UYGULAMASINDA YOLOV8 VE YOLOV9 ALGORİTMALARININ PERFORMANS DEĞERLENDİRMESİ

Giriş

Nesne tespiti, insan müdahalesi gerektiren süreçlerde zaman kaybı, hata riski ve maliyet gibi sorunlara yol açabilmektedir. Bilgisayarlı görme ve makine öğrenmesi teknikleri, bu sorunlara etkili çözümler sunmaktadır. Gemi tespiti, deniz trafiği yönetimi, liman güvenliği ve askeri operasyonlar gibi birçok alanda kritik bir öneme sahiptir.

Uzaktan algılama teknolojisi, uydular ve hava araçları aracılığıyla geniş alanları düşük maliyetle gözlemleme imkânı sunarak gemi tespitinde yaygın olarak kullanılmaktadır. Ancak, karmaşık deniz ortamları, ölçek değişimleri ve nesne yoğunluğu gibi zorluklar, tespit sürecini güçleştirmektedir. YOLO tabanlı nesne tespit modelleri, bu alanda yüksek hız ve doğruluk sağlamasıyla öne çıkmaktadır. Son yıllarda geliştirilen SAR-LtYOLOv8 ve Ship-Fire Net gibi modeller, küçük nesnelerin tespiti ve deniz ortamındaki zorluklara karşı çeşitli iyileştirmeler sunarak başarılarını artırmıştır.

Bu çalışmada, YOLOv8 ve YOLOv9 modelleri kullanılarak uzaktan algılama ile gemi tespiti gerçekleştirilmiştir. Çalışmanın ikinci bölümünde kullanılan yöntemler ve veri seti tanıtılmış, üçüncü bölümde deneysel sonuçlar ele alınmış, dördüncü bölümde ise genel değerlendirme yapılmıştır.

Materyal ve Metot (Material and Method)

Bu çalışmada, YOLO algoritması ve en güncel sürümleri olan YOLOv8 ve YOLOv9 ele alınmıştır. YOLO, nesne tespitinde tek aşamalı bir yöntem olup, görüntüyü doğrudan giriş olarak kullanarak sınır kutuları ve sınıf olasılıklarını belirleyen bir modeldir. YOLOv8, Ocak 2023'te Ultralytics tarafından tanıtılmış ve C2f modülü ile gradyan akışını iyileştirerek modelin öğrenme yeteneğini artırmıştır. YOLOv9 ise CSPDarknet53 ve çeşitli diğer blokları entegre ederek daha yüksek doğruluk oranları sağlamıştır.

Veri Seti: Çalışmada, Kaggle'da barındırılan ve Roboflow tarafından erişime açılan *Ships in Google Earth* veri seti kullanılmıştır. Toplamda 1658 uydu görüntüsü içeren veri seti; eğitim (%86), doğrulama (%10) ve test (%5) olarak üçe ayrılmıştır. Görüntüler, 640x640 piksele ölçeklendirilmiş ve veri artırma teknikleri (yatay çevirme, 90° döndürme) uygulanarak modelin daha geniş varyasyonları öğrenmesi sağlanmıştır.

Araştırma Bulguları (Research Findings)

Bu çalışmada YOLOv8 ve YOLOv9 modellerinin nesne tespit performansları karşılaştırılmıştır. Eğitim süreci boyunca her iki model de 25 iterasyon çalıştırılmış ve batch_size değeri 16 olarak belirlenmiştir. 25 iterasyon sonunda modelin başarısındaki değişim azaldığı için eğitim süreci tamamlanmıştır. Model performansı kesinlik (Precision), duyarlılık (Recall) ve ortalama hassasiyet (mAP) metrikleri kullanılarak değerlendirilmiştir.

Kesinlik, duyarlılık ve ortalama hassasiyet metriklerinin hesaplanması için formüller şu şekildedir:

- Kesinlik (Precision), doğru pozitiflerin (TP), doğru pozitifler ile yanlış pozitiflerin (FP) toplamına oranı olarak hesaplanır.

- Duyarlılık (Recall), doğru pozitiflerin (TP), doğru pozitifler ile yanlış negatiflerin (FN) toplamına oranıdır.
- Ortalama hassasiyet (mAP), farklı sınıfların ortalama kesinlik değerlerinin hesaplanmasıyla elde edilir ve modelin genel başarımını gösterir.

Modellerin eğitim sürecindeki performans değişimleri grafiklerle analiz edilmiştir. YOLOv8 ve YOLOv9'un eğitim kayıpları, iterasyon sayısı arttıkça azalma eğilimi göstermiştir. YOLOv8'in kayıp eğrileri daha yumuşak bir düşüş sergileyerek daha stabil bir eğitim süreci sunduğunu göstermektedir. Buna karşılık, YOLOv9'un eğitim kayıpları başlangıçta daha hızlı düşmüş ve modelin daha hızlı yakınsadığını göstermiştir.

Doğrulama kayıpları açısından bakıldığında, her iki modelin doğrulama kayıpları zamanla azalmış ancak eğitim kayıplarına göre daha fazla dalgalanma göstermiştir. YOLOv9'un doğrulama kayıpları son iterasyonlarda biraz daha düşük olup, doğrulama setinde daha iyi bir genelleme yaptığı gözlemlenmiştir. Bununla birlikte, her iki modelin de doğrulama kayıplarında gözlemlenen dalgalanmalar, veri artırımı veya ek düzenleme yöntemleriyle iyileştirilebilir.

Kesinlik ve duyarlılık açısından değerlendirildiğinde, YOLOv9 eğitim sürecinin başında YOLOv8'e göre daha yüksek değerlere ulaşmış ve özellikle veri seti üzerinde daha başarılı bir tespit kapasitesine sahip olduğunu göstermiştir. YOLOv8'in duyarlılığı başlangıçta daha düşük olmasına rağmen, zamanla YOLOv9'un seviyelerine yaklaşmıştır. Ortalama hassasiyet (mAP) açısından YOLOv9, özellikle ilk iterasyonlarda YOLOv8'e kıyasla daha yüksek değerler elde etmiştir.

Genel olarak, YOLOv9'un $mAP@0.5:0.95$ değeri ile $mAP@0.5$ değeri arasındaki farkın küçük olması, her iki modelin de yüksek Intersection over Union (IoU) eşiklerinde başarılı olduğunu göstermektedir. Bununla birlikte, YOLOv9'un küçük veya kısmen gizli nesneleri tespit etme konusunda YOLOv8'e kıyasla bir miktar üstünlük sağladığı görülmüştür.

Sonuç olarak, YOLOv9'un eğitim sürecinde daha hızlı yakınsadığı, daha yüksek doğruluk oranlarına ulaştığı ve özellikle küçük nesnelerin tespitinde YOLOv8'e göre daha başarılı olduğu tespit edilmiştir. Ancak her iki modelde de doğrulama kayıplarında dalgalanmalar olduğu için veri artırımı veya ek düzenleme tekniklerinin kullanılması model performansını daha da iyileştirebilir.

Sonuç

Bu çalışmada YOLOv8 ve YOLOv9 modelleri, gemi tespiti uygulaması için karşılaştırılmıştır. YOLOv9, mAP ve duyarlılık açısından YOLOv8'e göre biraz daha iyi performans göstermiştir. Özellikle erken iterasyonlarda daha hızlı yakınsadığı ve daha az iterasyon ile yüksek performans sunduğu gözlemlenmiştir. Eğer tespit kalitesi ön planda ise, YOLOv9 bu veri seti için daha uygun bir seçenek olabilir. Ancak, model seçimi aynı zamanda çıkarım hızı ve hesaplama verimliliği gibi faktörlere de bağlıdır.

Her iki model de gemi tespiti için etkili çözümler sunarken, YOLOv9'un daha yüksek performansı onu cazip bir seçenek haline getirmiştir. YOLOv8 ise daha geniş bir uygulama yelpazesine sahiptir. Bu nedenle, model seçimi uygulamanın gereksinimlerine ve mevcut kaynaklara göre belirlenmelidir.

Ayrıca, çalışmada YOLO mimarileri kullanılarak gemi sınıflandırması başarıyla gerçekleştirilmiştir. Literatürde, YOLO'nun farklı veri setleriyle de başarılı sonuçlar verdiği gösterilmiştir. Gelecekteki çalışmalarda, sadece gemi türleri değil, daha geniş kapsamlı deniz araçlarını içeren bir veri seti ile araştırmalar yapılması planlanmaktadır. YOLO mimarilerinin gelişimi, en güncel versiyonlarının kullanımıyla daha başarılı sonuçlar elde edilmesine olanak sağlayacaktır.